**Universidad de La Sabana**

# Evaluación de estrategias de inversión mediante aprendizaje por refuerzo

Nombre: Francis Segovia Chaves
Maestría en Inteligencia Artificial

## Resumen

Se implementó un entorno de inversión en SPY compatible con Gymnasium y se entrenaron agentes Deep Q Network con dos funciones de recompensa. Los datos diarios se dividieron cronológicamente en entrenamiento, validación y prueba. El estado incluyó retorno reciente, distancia a una media móvil, volatilidad y proporción invertida. Las acciones fijaron exposiciones objetivo de 0 %, 50 % y 100 %, con costos de transacción de 0,1 %.

La recompensa con penalización de rotación fue seleccionada por su mayor retorno promedio en validación. En la prueba de 2024-2025, el DQN obtuvo un retorno promedio de 16,42 % en tres semillas, frente a 48,39 % de comprar y mantener y 0,23 % del agente aleatorio. La desviación estándar del retorno del DQN fue 17,08 puntos porcentuales. El experimento no demuestra superioridad frente a comprar y mantener; evidencia la importancia de los costos, la variabilidad del entrenamiento y la evaluación temporal.

## Objetivo y pregunta de investigación

Evaluar si un agente de aprendizaje por refuerzo puede aprender una estrategia de exposición a un activo que se comporte mejor que comprar y mantener y que una política aleatoria en datos no vistos. Se prioriza una comparación reproducible que considere rendimiento, riesgo y costos, independientemente de que el agente produzca ganancias.

## 1 Datos y análisis exploratorio

La fuente fue **Yahoo Finance**, consultada con yfinance para SPY entre el 1 de enero de 2015 y el 1 de enero de 2026, con frecuencia diaria y auto_adjust=True. El extremo final es exclusivo. Se obtuvieron 2766 observaciones con fecha, apertura, máximo, mínimo, cierre y volumen. Los precios ajustados se tratan como una serie de simulación y no como cotizaciones históricas exactas de ejecución.

Se ordenaron las observaciones por fecha y se incluyeron comprobaciones de valores faltantes, fechas duplicadas y precios de cierre no positivos. Los indicadores se calcularon con ventanas retrospectivas. Se retiraron las primeras 20 filas que no permitían completar los indicadores; quedaron 2746 registros utilizables.

| Periodo | Registros | Inicio | Fin |
|---|---|---|---|
| Entrenamiento | 1743 | 2015-02-02 | 2021-12-31 |
| Validación | 501 | 2022-01-03 | 2023-12-29 |
| Prueba final | 502 | 2024-01-02 | 2025-12-31 |

Las ventanas de validación y prueba pueden usar observaciones históricas anteriores a su inicio para construir indicadores. Eso no introduce información futura. El normalizador se ajustó solamente con entrenamiento.

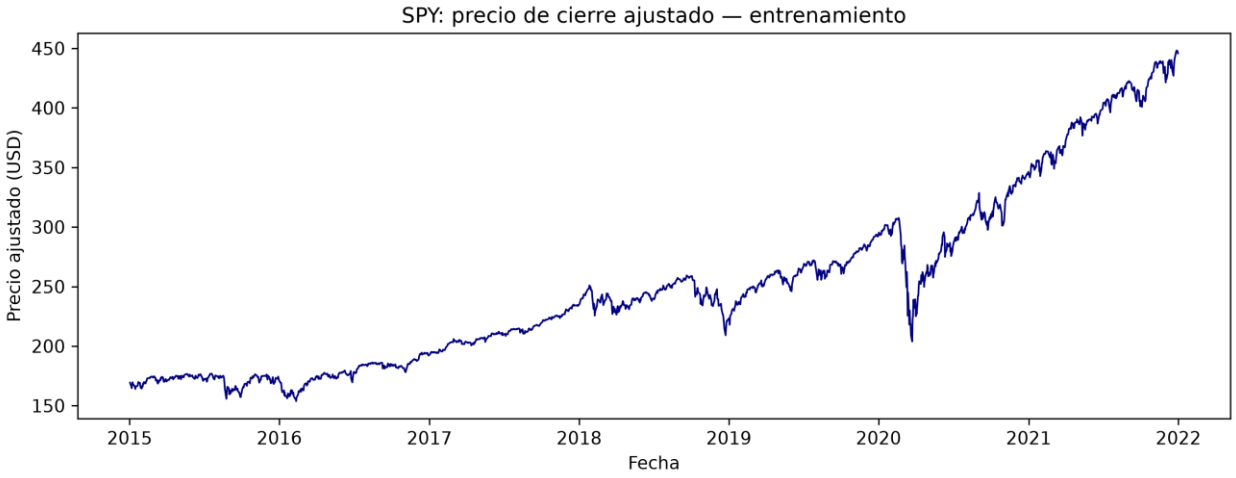



Figura 1. Evolución del precio ajustado en entrenamiento.

La serie presenta tendencias ascendentes y caídas de distinta intensidad. Esta variación justifica combinar una medida de tendencia con una de volatilidad en el estado del agente.

## 2 Indicadores y formulación del problema

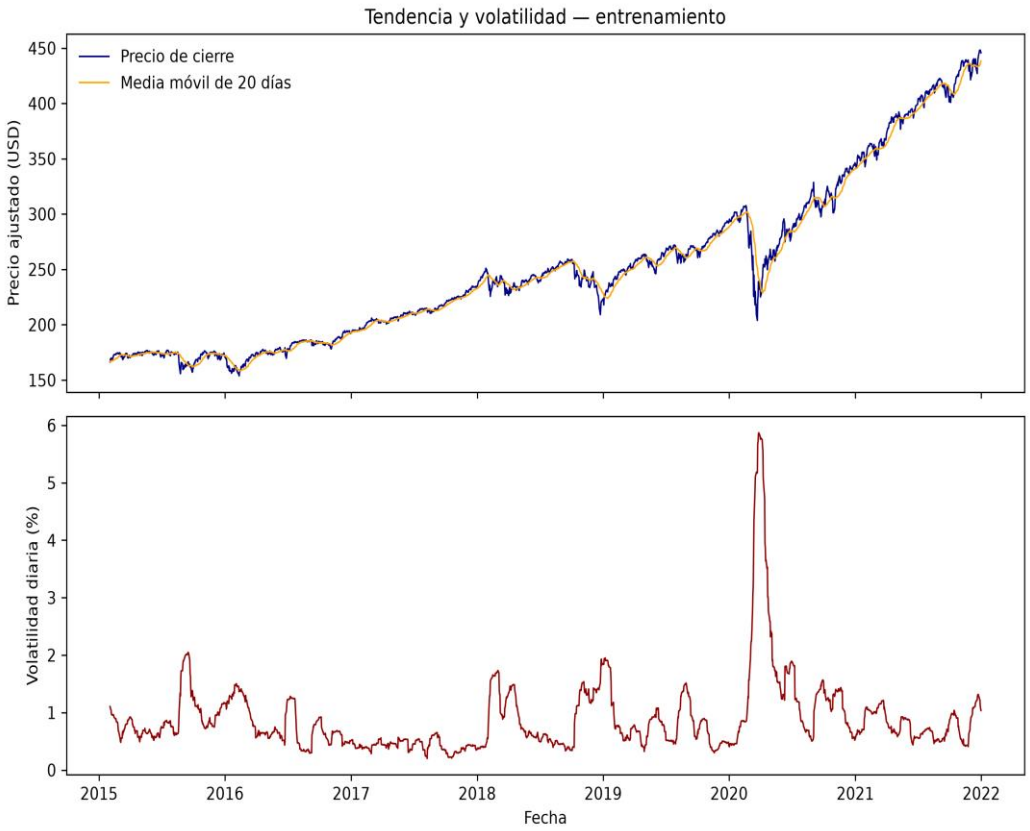



Figura 2. Precio, media móvil y volatilidad retrospectiva en entrenamiento.

En el análisis previo del entrenamiento se observaron 1762 retornos diarios: media de 0,0612 %, desviación estándar de 1,1134 %, mínimo de −10,9424 % y máximo de 9,0603 %. Estas estadísticas corresponden a la serie antes de retirar las filas iniciales sin indicadores. La media diaria no equivale al retorno acumulado.

El estado observado es $s_t = (z(R_t), z(D_t), z(\sigma_t), w_t)$, donde z representa StandardScaler ajustado con entrenamiento y $w_t$ es la proporción invertida al cierre. Esta representación resume parcialmente el mercado; no garantiza la propiedad de Markov de la dinámica financiera.

| Variable | Definición | Justificación |
|---|---|---|
| Retorno | $R_t = P_t / P_{t-1} - 1$ | Movimiento diario reciente |
| Distancia a la media | $D_t = P_t / MA_{20,t} - 1$ | Desviación relativa de la tendencia |
| Volatilidad | $\sigma_t$ = desviación estándar de 20 retornos | Variabilidad reciente |
| Posición | $w_t$ = valor invertido / capital | Exposición y costos de rebalanceo |

La media utiliza 20 cierres y la volatilidad 20 retornos de días de negociación. No se usan ventanas centradas ni escalamiento ajustado con períodos futuros.

| Acción | Exposición objetivo |
|---|---|
| 0 | 0 % |
| 1 | 50 % |
| 2 | 100 % |

Tres acciones facilitan la implementación de DQN. La representación no permite exposiciones intermedias adicionales, apalancamiento, posiciones cortas ni diversificación entre activos.

**3 Diseño y verificación del entorno**

Cada episodio inicia con 100 000 USD simulados en efectivo y termina en el último cierre del período. Se permiten participaciones fraccionarias, sin intereses sobre efectivo ni deuda. El agente observa el cierre del día t, fija una exposición y la ejecuta en la apertura del día t+1. El capital se valora posteriormente al cierre de t+1. El movimiento nocturno de las participaciones existentes queda incluido.

Sean E el efectivo, q las participaciones, O la apertura siguiente y C el cierre siguiente. Antes de operar, $H = qO \; y \; V^o = E + H$. Para exposición objetivo a y costo c = 0,001, el importe firmado Δ se calcula como:

$\Delta = (aV^{o} - H) / (1 + ac)$ si $aV^{o} - H \geq 0$

$\Delta = (aV^{o} - H) / (1 - ac)$ $si$ $aV^{o} - H < 0$

El costo es c|Δ|. Se actualiza $E' = E - \Delta - c|\Delta|$ $y$ $q' = q + \Delta/O$ . El capital siguiente es $V_{t+1} = E' + q'C$. Estas expresiones alcanzan el objetivo después de pagar la comisión. Repetir la acción del 50 % puede generar operaciones de rebalanceo aun sin cambiar de acción.

Al finalizar se conserva la posición y se valora a mercado, sin venta terminal ni comisión de liquidación. Todos los agentes usan esta misma convención. La primera fila aporta la observación inicial; la primera operación ocurre en la apertura de la segunda fila.

**Comprobaciones implementadas**

check_env verificó la interfaz de Gymnasium. Adicionalmente, mantener todo en efectivo conservó 100 000 USD sin costos; comprar y mantener coincidió con el cálculo analítico $Vfinal = 100\,000 \times Cfinal / [Oprimera \times (1 + c)]$. Se comprobó que la penalización adicional de recompensa no cambia el capital cuando las acciones son iguales. El notebook entregado no contiene salidas de error guardadas.

**Alcance del simulador**

No se modelan spread, deslizamiento, impuestos, restricciones de liquidez ni impacto de mercado. Los precios ajustados incorporan tratamientos corporativos del proveedor. La evaluación es un ejercicio académico de simulación, con hipótesis comunes para todas las estrategias.

## 4 Recompensa y algoritmo

La primera recompensa fue el retorno neto $r_{t+1}{}^{1} = V_{t+1}/V_t - 1$. Las comisiones ya están descontadas del capital. En el primer entrenamiento con semilla 42, el DQN perdió 20,98 % en validación, cambió de acción 297 veces y pagó 16567,35 USD. Ese comportamiento motivó una penalización adicional del importe operado.

La segunda recompensa fue $r_{t+1}{}^{2} = r_{t+1}{}^{1} - \eta|\Delta|/V_t$, con $\eta$ = 0,001. El término penaliza la rotación para orientar el aprendizaje; no representa una comisión adicional descontada del capital. Por tanto, la comparación financiera conserva los mismos costos de 0,1 %.

Se entrenaron ambas versiones desde cero con idénticos hiperparámetros. DQN aproxima Q(s,a), utiliza experiencias almacenadas en un replay buffer y una red objetivo. Se empleó MlpPolicy con cuatro entradas, dos capas ocultas de 64 neuronas y tres valores Q de salida. Se mantuvieron las activaciones y el optimizador predeterminados de la implementación utilizada.

| **Parámetro** | **Valor** |
|---|---|
| Tasa de aprendizaje | 0,0001 |
| Batch size | 64 |
| Descuento γ | 0,99 |
| Replay buffer | 50 000 transiciones |
| Inicio del aprendizaje | 2000 pasos |
| Actualización de red | Cada 4 pasos con 1 actualización de gradiente |
| Actualización de red objetivo | Cada 1000 pasos |
| Exploración ε | De 1,0 a 0,05 durante el primer 30 % |
| Presupuesto por entrenamiento | 50 000 pasos |
| Semillas | 42, 7 y 21 |
| Dispositivo | CPU |

El criterio de parada fue el presupuesto fijo de pasos. Cada episodio recorre los 1743 registros de entrenamiento y tiene 1742 transiciones. El presupuesto comprende aproximadamente 28 episodios completos y parte de otro. Las repeticiones no aportan nuevas observaciones históricas. No se efectuó búsqueda extensa de hiperparámetros ni selección por resultados de prueba.

## 5 Protocolo y resultados de validación

Comprar y mantener invierte todo en la primera apertura disponible y conserva las participaciones. El agente aleatorio elige uniformemente entre las tres acciones; se evaluaron diez semillas de 0 a 9. Las dos recompensas DQN se compararon con tres semillas de entrenamiento emparejadas. Durante evaluación, predict usa $deterministic = True$ y no actualiza los parámetros.

Las métricas son retorno acumulado, máximo drawdown y suma de comisiones. Se define $R = Vfinal/Vinicial - 1\, y\, MDD = max_t[1 - V_t/max_u \leq_t V_u]$. El drawdown se informa como magnitud positiva en las tablas y como caída negativa en las figuras.

| Versión | Retorno medio ± DE | MDD medio ± DE | Costos medios USD |
|---|---|---|---|
| v1 | −16,29 ± 4,24 % | 24,82 ± 2,34 % | 13 440,49 |
| v2 | −3,87 ± 8,83 % | 21,89 ± 5,45 % | 12 767,29 |

La segunda recompensa mejoró el retorno promedio en 12,42 puntos porcentuales y redujo el drawdown promedio en 2,93 puntos. Sin embargo, ambas medias quedaron por debajo del 2,22 % de comprar y mantener. La dispersión del retorno aumentó con v2; mejorar el promedio no equivale a mejorar la estabilidad.

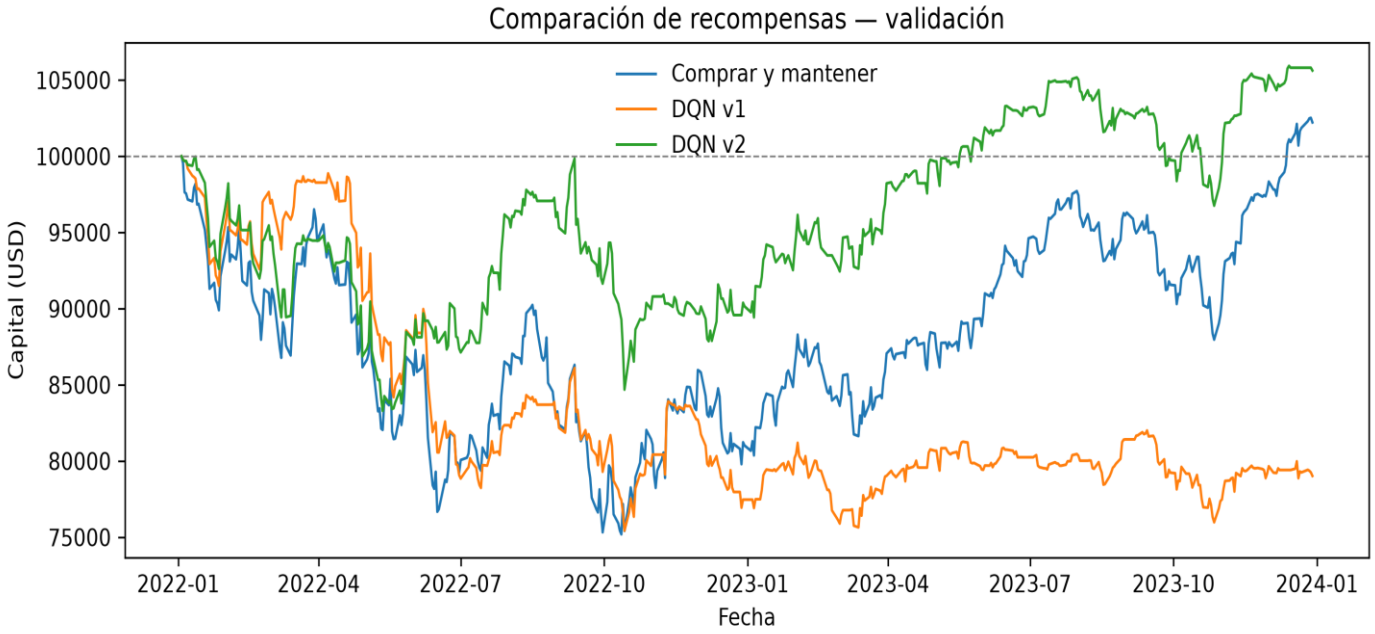



Figura 3. Comparación en validación para la semilla 42.

Para la semilla 42, v2 obtuvo 5,63 % frente a −20,98 % de v1. Los cambios de acción disminuyeron de 297 a 230 y los costos de 16 567,35 a 14 935,05 USD. Esta mejora particular no representa el promedio de las tres semillas.

## 6 Evaluación final en datos no vistos

Se seleccionó v2 por mayor retorno neto promedio en validación, con menor drawdown como desempate. El criterio quedó registrado antes de la prueba, aunque después de los experimentos iniciales de validación; no constituye un protocolo prerregistrado. Se conservaron las tres semillas y no se reentrenó con validación ni se hicieron ajustes posteriores al observar la prueba.

| Estrategia | Retorno % | MDD % | Costos USD |
|---|---|---|---|
| Comprar y mantener | 48,39 | 18,76 | 99,90 |
| Aleatorio media de 10 | −0,23 | 15,63 | 22 574,40 |
| DQN v2 media de 3 | 16,42 | 17,07 | 12 196,09 |

| Semilla DQN | Capital final USD | Retorno % | MDD % | Costos USD |
|---|---|---|---|---|
| 42 | 97 804,23 | −2,20 | 22,00 | 14 910,60 |
| 7 | 131 358,58 | 31,36 | 11,63 | 12 306,06 |
| 21 | 120 085,60 | 20,09 | 17,59 | 9371,61 |

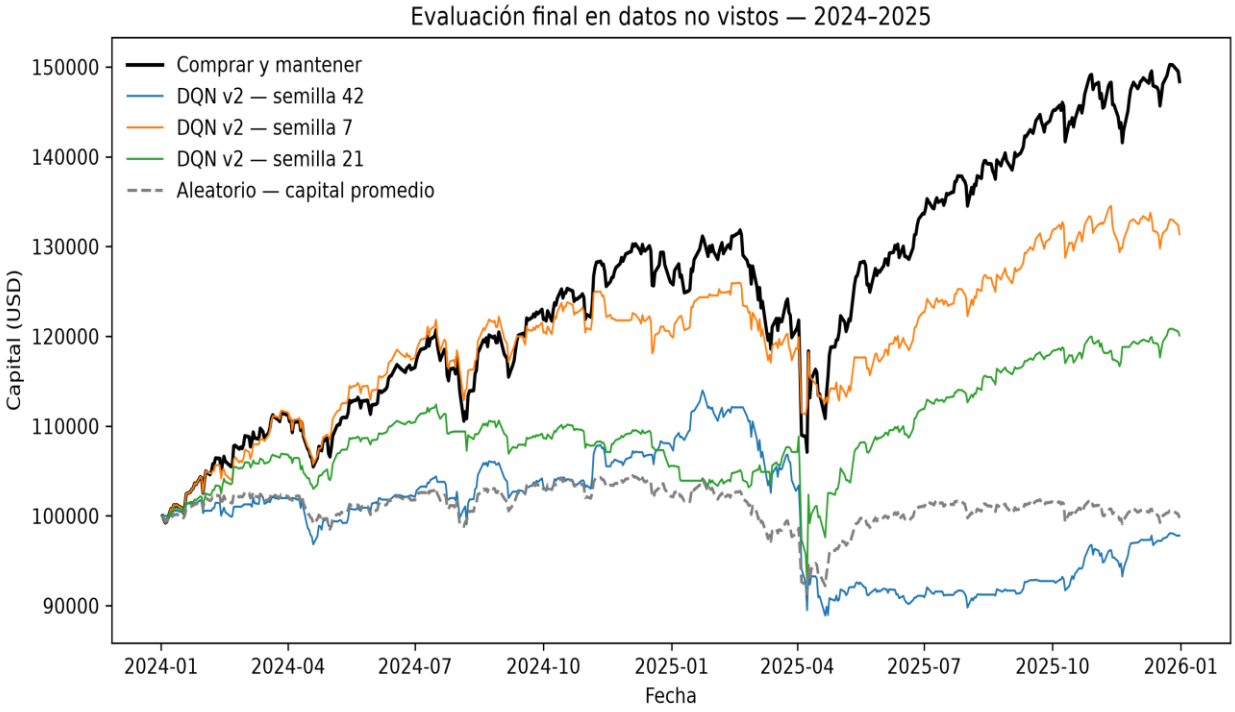



Figura 4. Capital de los tres DQN y estrategias de referencia en prueba.

El retorno promedio del DQN fue 16,65 puntos porcentuales mayor que el aleatorio y 31,97 puntos menor que comprar y mantener. Ninguna semilla DQN superó el retorno de comprar y mantener. Su desviación estándar del retorno fue 17,08 puntos, frente a 8,54 puntos del aleatorio. Las medias de drawdown son promedios de métricas individuales, no drawdowns de curvas promedio.

## 7 Comportamiento y caso de pérdida

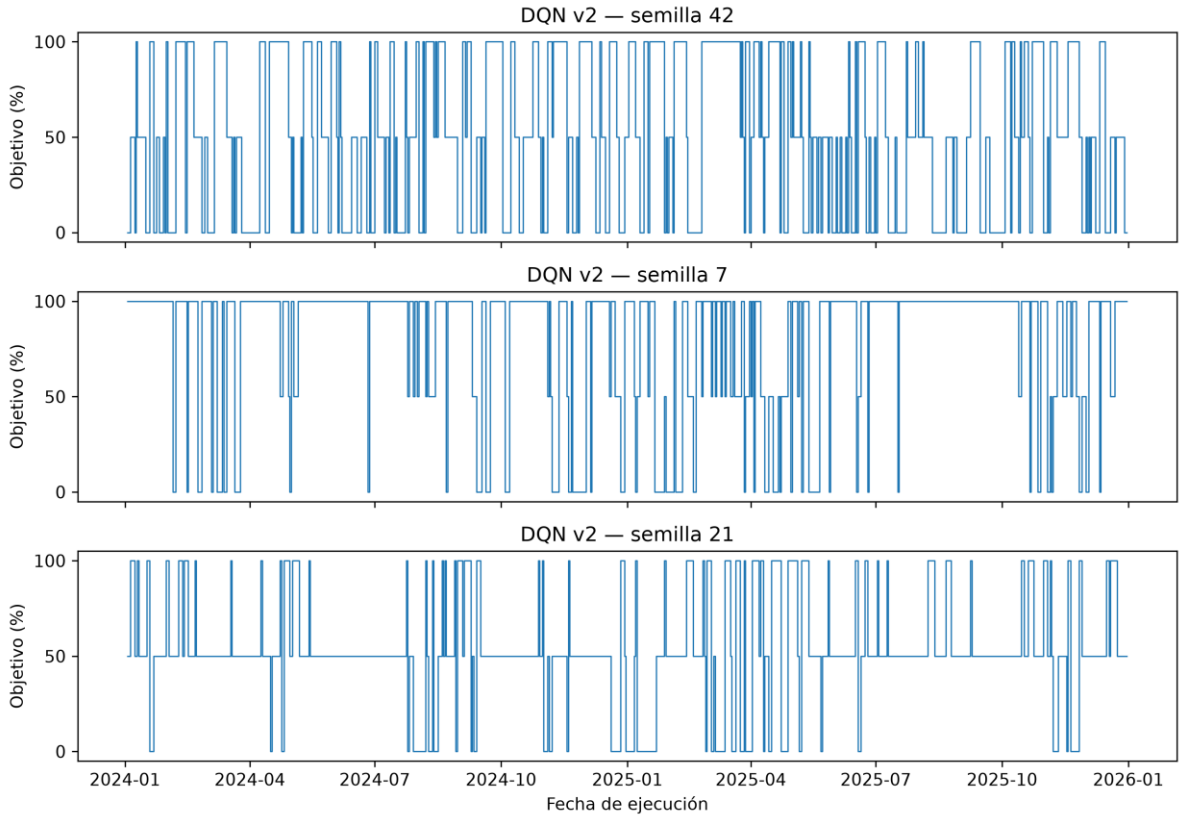



Figura 5. Exposiciones objetivo ejecutadas por las tres semillas en prueba.

Los modelos aprendieron políticas diferentes pese a usar los mismos datos e hiperparámetros. La variación entre semillas se relaciona con la inicialización de la red y la exploración, pero los registros disponibles no permiten aislar la contribución causal de cada mecanismo.

### Pérdida del 4 de abril de 2025

En la semilla 42, el capital pasó de 99 974,89 USD el 3 de abril a 94 122,07 USD el 4 de abril, una pérdida diaria de 5,8543 %. En ambos días la exposición objetivo fue 100 %. El 4 de abril no se registró operación ni comisión; la caída provino del movimiento del activo con la posición ya mantenida.

El 7 de abril el objetivo disminuyó a 50 %, pero el 8 de abril volvió a 100 %. El capital terminó ese día en 89 499,88 USD. Este caso documenta una limitación observable: la

política no evitó la exposición completa durante ese episodio de caída. No demuestra que el agente conociera o pudiera predecir el evento.

| Fecha | Objetivo % | Capital USD | Retorno diario % | Costo USD |
|---|---|---|---|---|
| 2025-04-03 | 100 | 99 974,89 | −3,30 | 51,20 |
| 2025-04-04 | 100 | 94 122,07 | −5,85 | 0,00 |
| 2025-04-07 | 50 | 92 493,35 | −1,73 | 45,59 |
| 2025-04-08 | 100 | 89 499,88 | −3,24 | 45,49 |

## 8 Discusión y reflexión individual

La recompensa de rotación fue útil para mejorar el promedio de validación, pero los costos siguieron siendo elevados. El DQN pagó en prueba 12196,09 USD en promedio, equivalente al 12,20 % del capital inicial. Esa proporción no mide directamente el retorno que se recuperaría al eliminar costos, porque cambiar las comisiones también puede cambiar el aprendizaje y la capitalización.

La generalización se evaluó en un solo activo y un solo período de prueba. Tres semillas permiten observar variabilidad, pero no estimar con precisión la distribución del rendimiento ni establecer significancia estadística. El estado usa pocos indicadores y la simulación omite fricciones de mercado. El descuento $\gamma = 0{,}99$ y la suma de retornos diarios recompensados tampoco equivalen exactamente a maximizar riqueza final compuesta.

La elección de SPY, los indicadores y los hiperparámetros forma parte del diseño del experimento. Los datos ajustados pueden revisarse por el proveedor. La reproducción exacta requiere conservar el CSV original, el normalizador, las versiones y los modelos, además del notebook.

**Resultado que requiere mayor atención**

La diferencia entre semillas fue considerable: una perdió capital y dos obtuvieron retornos positivos. Esto muestra que el resultado de un único entrenamiento no basta para juzgar el algoritmo.

**Decisión metodológica de mayor impacto**

La modificación de la recompensa mejoró el retorno promedio de validación, y la separación temporal permitió contrastar ese resultado con un período nuevo. No se aisló experimentalmente cuál de todas las decisiones tuvo el mayor impacto causal.

**Cambios en un nuevo experimento**

Se propone ampliar el número de semillas y períodos mediante validación temporal sucesiva, incluir spread y deslizamiento y comparar un control sencillo de tendencia. Cualquier nuevo ajuste requeriría un nuevo período de prueba reservado.

**Comportamiento no explicado completamente**

La exposición elegida alrededor de abril de 2025 y las diferencias entre semillas no quedan completamente explicadas por las métricas agregadas. Un análisis futuro puede inspeccionar valores Q y estados concretos.

**Diferencia entre teoría y aplicación**

En una serie histórica el agente observa una trayectoria finita y puede sobreajustarse a ella. Diseñar el entorno, definir cuándo se conoce cada precio y pagar costos es tan determinante para la evaluación como implementar la red neuronal.

## 9 Conclusiones y reproducción

Bajo las condiciones estudiadas, DQN no superó a comprar y mantener en los datos de prueba. La recompensa con penalización de rotación mejoró el promedio de validación y fue seleccionada sin utilizar la prueba final. En 2024–2025 produjo 16,42 % de retorno promedio y 17,07 % de máximo drawdown promedio, con variabilidad importante entre

entrenamientos. El resultado apoya una conclusión limitada al experimento, no una ventaja general del aprendizaje por refuerzo para invertir.

**Instrucciones de reproducción en el notebook (jupyter)**

1. Crear un entorno con Python 3.11 e instalar las dependencias registradas en requirements.txt. Seleccionar ese kernel en Jupyter.
2. Abrir Actividad_RL_Inversion.ipynb desde la carpeta del proyecto. Colocar data, models y results junto al notebook. Priorizar el CSV conservado para evitar diferencias por una nueva descarga.
3. Ejecutar preparación de datos, indicadores y normalizador en orden. Definir EntornoInversion y EntornoInversionRotacion y ejecutar las comprobaciones.
4. Entrenar ambas recompensas con 50 000 pasos y semillas 42, 7 y 21. Comparar en validación y mantener la selección v2. Para reproducir la evaluación ya realizada, cargar los modelos guardados y escalador.joblib.
5. Evaluar las tres semillas v2 y las diez aleatorias en prueba sin ajustar parámetros. Calcular métricas, exportar historiales y generar figuras. Conservar versiones y configuración.

**Referencias**

Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction (2nd ed.). MIT Press. https://incompleteideas.net/book/the-book-2nd.html

Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. Nature, 518, 529–533. https://doi.org/10.1038/nature14236

Raffin, A., et al. (2021). Stable-Baselines3: Reliable reinforcement learning implementations. Journal of Machine Learning Research, 22(268), 1–8. https://jmlr.org/papers/v22/20-1364.html

Farama Foundation. (s. f.). Gymnasium documentation. https://gymnasium.farama.org/

yfinance. (s. f.). Download market data from Yahoo Finance. https://ranaroussi.github.io/yfinance/

Yahoo Finance. (s. f.). SPY historical data. https://finance.yahoo.com/quote/SPY/history/